

Subject Name (Gujarati)

4351601 -- Summer 2024

Semester 1 Study Material

Detailed Solutions and Explanations

પ્રશ્ન 1(અ) [3 ગુણ]

Narrow AI અથવા Weak AI નો અર્થ શું છે?

જવાબ

Narrow AI અથવા Weak AI એ specific અને limited કાર્યો માટે બનાવેલ artificial intelligence systems છે.
ટેબલ: Narrow AI ની લાક્ષણિકતાઓ

પાસું	વર્ણન
વ્યાપ્તિ	ફક્ત specific કાર્યો માટે
બુદ્ધિમત્તા	કાર્ય-વિશિષ્ટ કુશળતા
ઉદાહરણો	Siri, chess programs, recommendation systems
શીખવાની પ્રક્રિયા	Domain માં pattern recognition

મેમરી ટ્રીક

"Narrow = ફક્ત વિશિષ્ટ કાર્યો"

પ્રશ્ન 1(બ) [4 ગુણ]

વ્યાખ્યાયિત કરો: વર્ગીકરણ, રીગ્રેસન, કલ્યાસ્ટરિંગ, એસોસિએશન વિશ્લેષણ.

જવાબ

ટેબલ: Machine Learning ની તકનીકો

તકનીક	વ્યાખ્યા	પ્રકાર	ઉદાહરણ
વર્ગીકરણ (Classification)	Discrete categories/classes predict કરે છે	Supervised	Email spam detection
રીગ્રેસન (Regression)	Continuous numerical values predict કરે છે	Supervised	House price prediction
કલ્યાસ્ટરિંગ (Clustering)	Similar data points ને group કરે છે	Unsupervised	Customer segmentation
એસોસિએશન વિશ્લેષણ	Variables વચ્ચે relationships શોધે છે	Unsupervised	Market basket analysis

મેમરી ટ્રીક


"CRCA - Categories, Real numbers, Clusters, Associations"

પ્રશ્ન 1(ક) [7 ગુણ]

ન્યુરોનના જણ મુખ્ય ઘટકોને પ્રકાશિત કરો.

જવાબ

Biological neuron ના ત્રણ મુખ્ય ઘટકો જે artificial neural networks ને inspire કરે છે:
ડાયાગ્રામ:



ટેબલ: ન્યૂરોન ઘટકો

ઘટક	કાર્ય	AI માં સમકક્ષ
Dendrites	અન્ય neurons થી input signals receive કરે છે	Input layer/weights
Cell Body (Soma)	Signals ને process અને integrate કરે છે	Activation function
Axon	અન્ય neurons ને output signals transmit કરે છે	Output connections

મુખ્ય મુદ્દાઓ:

- **Dendrites:** વિવિધ connection strengths સાથે input receivers તરીકે કામ કરે છે
- **Cell Body:** Inputs ને sum કરે છે અને threshold function apply કરે છે
- **Axon:** Processed signal ને આગામના neurons સુધી પહોંચાડે છે

મેમરી ટ્રીક

"DCA - Dendrites Collect, Cell-body Calculates, Axon Announces"

પ્રશ્ન 1(ક) OR [7 ગુણ]

Artificial Neural Network માં back propagation પદ્ધતિ સમજાવો.

જવાબ

Back Propagation એ supervised learning algorithm છે જે gradient descent દ્વારા error minimize કરીને multi-layer neural networks ને train કરે છે.

ફ્લોચાર્ટ:

Mermaid Diagram (Code)

```

{Shaded}
{Highlighting} []
graph LR
    A[Forward Pass] --> B[Output Calculate]
    B --> C[Error Calculate]
    C --> D[Backward Pass]
    D --> E[Gradients Calculate]
    E --> F[Weights Update]
    F --> G{\Error ?\}
    G --> H[Training Complete]
{Highlighting}
{Shaded}

```

ટેબલ: Back Propagation Steps

સ્ટેપ	પ્રક્રિયા	ફોર્મ્યુલા
Forward Pass	Layer દ્વારા layer outputs calculate કરો	$y = f(\sum(w_i * x_i + b))$
Error Calculation	Loss function compute કરો	$E = \frac{1}{2}(target - output)^2$
Backward Pass	Error gradients calculate કરો	$\Delta = /$
Weight Update	Learning rate વાપરીને weights adjust કરો	$w_{new} = w_{old} - \eta * \Delta$

મુખ્ય લાક્ષણિકતાઓ:

- **Gradient Descent:** Minimum error શોધવા માટે calculus વાપરે છે
- **Chain Rule:** Layers દ્વારા error ને backward propagate કરે છે
- **Learning Rate:** Weight updates ની speed control કરે છે

મેમરી ટ્રીક

“FEBU - Forward, Error, Backward, Update”

પ્રશ્ન 2(અ) [3 ગુણ]

Machine Learning માં ઉપયોગમાં લેવાતા કોઈપણ પાંચ લોકપ્રિય algorithms ની સૂચિ બનાવો.

જવાબ

ટેબલ: લોકપ્રિય ML Algorithms

Algorithm	પ્રકાર	Application
Linear Regression	Supervised	Continuous values નું prediction
Decision Tree	Supervised	Classification અને regression
K-Means Clustering	Unsupervised	Data grouping
Support Vector Machine	Supervised	Margins સાથે classification
Random Forest	Supervised	Ensemble learning

મેમરી ટ્રીક

“LDKSR - Learn Data, Keep Samples, Run”

પ્રશ્ન 2(બ) [4 ગુણ]

નિષ્ણાત સિસ્ટમ શું છે? તેની મર્યાદાઓ અને applications ની યાદી બનાવો.

જવાબ

Expert System એ AI program છે જે specific domains માં complex problems solve કરવા માટે human expert knowledge ને mimic કરે છે.

ટેબલ: Expert System Overview

પાસું	વિગતો
વ્યાખ્યા	Domain-specific expertise સાથે AI system
ઘટકો	Knowledge base, inference engine, user interface

Applications:

- **Medical Diagnosis:** रोग identification systems
- **Financial Planning:** Investment advisory systems
- **Fault Diagnosis:** Equipment troubleshooting

મહિદાયો:

- **Limited Domain:** ફક્ત specific areas માં કામ કરે છે
- **Knowledge Acquisition:** Expert knowledge extract કરવું મુશ્કેલ
- **Maintenance:** Rules update અને modify કરવા મુશ્કેલ

મેમરી ટ્રીક

“EXPERT - Explains Problems, Executes Rules, Tests”

પ્રશ્ન 2(ક) [7 ગુણ]

ટોકનાઇઝેશન શું છે? યોગ્ય ઉદાહરણ સાથે સમજાવો.

જવાબ

Tokenization એ text ને smaller units (tokens) માં break down કરવાની process છે NLP processing માટે.
ટેચ્વલ: Tokenization ના પ્રકારો

પ્રકાર	વર્ણન	ઉદાહરણ
Word Tokenization	Words દ્વારા split કરે છે	“Hello world” → ["Hello", "world"]
Sentence Tokenization	Sentences દ્વારા split કરે છે	“Hi. How are you?” → ["Hi.", "How are you?"]
Subword Tokenization	Subwords માં split કરે છે	“unhappy” → ["un", "happy"]

Code ઉદાહરણ:

```
import nltk
text = "Natural Language Processing is amazing!"
tokens = nltk.word_tokenize(text)
# Output: [{"Natural", "Language", "Processing", "is", "amazing", !}]
```

Process Flow:

Mermaid Diagram (Code)

```
{Shaded}
{Highlighting} []
graph LR
    A[Raw Text] --> B[Tokenization]
    B --> C[Clean Tokens]
    C --> D[Further Processing]
{Highlighting}
{Shaded}
```

મુખ્ય ફિયદા:

- **Standardization:** Text ને uniform format માં convert કરે છે
- **Analysis Ready:** ML algorithms માટે text prepare કરે છે
- **Feature Extraction:** Statistical analysis enable કરે છે

મેમરી ટ્રીક

“TOKEN - Text Operations Keep Everything Normalized”

પ્રશ્ન 2(અ) OR [3 ગુણ]

સુપરવાઇઝ અને અનસુપરવાઇઝ લર્નિંગની સરખામણી કરો.

જવાબ

ટેબલ: Supervised vs Unsupervised Learning

પાસું	Supervised Learning	Unsupervised Learning
Training Data	Target outputs સાથે labeled data	Targets બિના unlabeled data
લક્ષ્ય	Specific outcomes predict કરવા	Hidden patterns discover કરવા
ઉદાહરણો	Classification, Regression	Clustering, Association rules
મૂલ્યાંકન	Accuracy, precision, recall	Silhouette score, elbow method
Applications	Email spam, price prediction	Customer segmentation, anomaly detection

મેમરી ટ્રીક

“SU - Supervised Uses labels, Unsupervised Uncovers patterns”

પ્રશ્ન 2(બ) OR [4 ગુણ]

હેલ્થકેર, ફાઇનાન્સ અને મેન્યુફલ્કચરિંગમાં AI applications વિશે બધું સમજાવો.

જવાબ

ટેબલ: Industry પ્રમાણે AI Applications

Industry	Applications	ફાયદા
Healthcare	Medical imaging, drug discovery, diagnosis	Improved accuracy, faster treatment
Finance	Fraud detection, algorithmic trading, credit scoring	Risk reduction, automated decisions
Manufacturing	Quality control, predictive maintenance, robotics	Efficiency, cost reduction

Healthcare ઉદાહરણો:

- Medical Imaging: X-rays અને MRIs માં AI cancer detect કરે છે
- Drug Discovery: AI નવી medicine development ને accelerate કરે છે

Finance ઉદાહરણો:

- Fraud Detection: Real-time transaction monitoring
- Robo-advisors: Automated investment management

Manufacturing ઉદાહરણો:

- Quality Control: Automated defect detection
- Predictive Maintenance: Equipment failure prediction

મેમરી ટ્રીક

“HFM - Health, Finance, Manufacturing benefit from AI”

પ્રશ્ન 2(ક) OR [7 ગુણ]

સિન્ટેક્ટિક વિશ્લેષણ શું છે અને તે લેક્સિકલ વિશ્લેષણથી કેવી રીતે અલગ છે?

જવાબ

Syntactic Analysis sentences ના grammatical structure ને examine કરે છે, જ્યારે **Lexical Analysis** text ને meaningful tokens માં break કરે છે.

ટેબલ: Lexical vs Syntactic Analysis

પાસું	Lexical Analysis	Syntactic Analysis
કૃત્તુ	Text ને words માં tokenize કરવા	Grammatical structure parse કરવા
Input	Raw text	Lexical analysis થી tokens
Output	Tokens, part-of-speech tags	Parse trees, grammar rules
ધ્યાન	Individual words	Sentence structure
ઉદાહરણ	"The cat runs" → [The, cat, runs]	Noun-verb relationship દર્શાવું parse tree બનાવે છે

Process Flow:

Mermaid Diagram (Code)

```
{Shaded}
{Highlighting} []
graph LR
    A[Raw Text] --> B[Lexical Analysis]
    B --> C[Tokens]
    C --> D[Syntactic Analysis]
    D --> E[Parse Tree]
{Highlighting}
{Shaded}
```

ઉદાહરણ:

- Lexical: "She reads books" → ["She", "reads", "books"]
- Syntactic: "She" ને subject, "reads" ને verb, "books" ને object તરીકે identify કરે છે

મુખ્ય ત્રફાવતો:

- Scope: Lexical words પર કામ કરે છે, Syntactic sentence structure પર
- જાણિલતા: Syntactic analysis lexical કરતાં વધુ complex છે
- Dependencies: Syntactic analysis lexical analysis પર depend કરે છે

મેમરી ટ્રીક

“LEX-SYN: LEXical extracts, SYNtactic structures”

પ્રશ્ન 3(અ) [3 ગુણ]

પ્રતિક્રિયાશીલ મશીનોની વિવિધ લાક્ષણિકતાઓની ચાર્ટી બનાવો.

જવાબ

ટેબલ: Reactive Machines ની લાક્ષણિકતાઓ

લાક્ષણિકતા	વર્ણન
કોઈ મેમરી નથી	Past experiences store કરી શકતા નથી
વર્તમાન-કેન્દ્રિત	જેક્સ ક્રિએટ્ચર current input ને respond કરે છે
નિયર્દિષ્ટ	Same input માટે same output આપે છે
કાર્ય-વિશિષ્ટ	Particular functions માટે design કરેલ
કોઈ શીખતું નથી	Experience થી improve કરી શકતા નથી

ઉદાહરણો:

- Deep Blue: IBM નું chess computer
- Game AI: Tic-tac-toe programs

મેમરી ટ્રીક

“REACT - Responds Exactly, Always Consistent Tasks”

પ્રશ્ન 3(બ) [4 ગુણ]

તફાવત કરો: હકારાત્મક મજબૂતીકરણ V/S નકારાત્મક મજબૂતીકરણ

જવાબ

ટેબલ: Positive vs Negative Reinforcement

પાસું	Positive Reinforcement	Negative Reinforcement
વાચ્યા	Good behavior માટે reward add કરવું	Good behavior માટે penalty remove કરવું
Action	કંઈક desirable આપવું	કંઈક undesirable દૂર કરવું
લક્ષ્ય	Desired behavior increase કરવું	Desired behavior increase કરવું
ઉદાહરણ	Correct answer માટે treat આપવું	Good performance માટે extra work દૂર કરવું

ડાયાગ્રામ:

$$\begin{array}{ll}
 \text{Positive Reinforcement:} & \text{Negative Reinforcement:} \\
 \text{Good Behavior} & \text{Good Behavior} \\
 + & + \\
 \text{Add Reward} & \text{Remove Penalty} \\
 = & = \\
 \text{Behavior Increases} & \text{Behavior Increases}
 \end{array}$$

મુખ્ય મુદ્દાઓ:

- બંને behavior increase કરે છે પરંતુ વિવિધ mechanisms દ્વારા
- Positive કંઈક pleasant add કરે છે
- Negative કંઈક unpleasant remove કરે છે

મેમરી ટ્રીક

“PN - Positive adds Nice things, Negative removes Nasty things”

પ્રશ્ન 3(ક) [7 ગુણ]

ટર્મ-ફીકવન્સી-ઇનવર્સ ડોક્યુમેન્ટ ફીકવન્સી (TF-IDF) word embedding technique વિશે બધું સમજવો.

જવાબ

TF-IDF એ numerical statistic છે જે documents ના collection માં કોઈ document માટે word કેટલું important છે તે reflect કરે છે.

ફિર્મ્યુલા:

$$\begin{aligned}
 \text{TF-IDF} &= \text{TF}(t,d) \times \text{IDF}(t) \\
 &: \\
 \text{TF}(t,d) &= (\text{Document } d \text{ term } t) / (\text{Document } d \text{ total terms}) \\
 \text{IDF}(t) &= \log((\text{Total documents}) / (\text{Term } t \text{ documents}))
 \end{aligned}$$

ટેબલ: TF-IDF ઘટકો

ઘટક	ફોર્મ્યુલા	ઉદ્દેશ્ય
Term Frequency (TF) Inverse Document Frequency (IDF)	$tf(t,d) = \text{count}(t,d) / idf(t) = \log(N / df(t))$	d Corpus માં word importance measure કરે છે
TF-IDF Score	$tf-idf(t,d) = tf(t,d) \times idf(t)$	Final word importance score

ઉદાહરણ Calculation:

- Document: "cat sat on mat"
- Term: "cat"
- TF = 1/4 = 0.25
- જો "cat" 10 માંથી 2 documents માં આવે છે: IDF = $\log(10/2) = 0.699$
- TF-IDF = $0.25 \times 0.699 = 0.175$

Applications:

- **Information Retrieval:** Search engines
- **Text Mining:** Document similarity
- **Feature Extraction:** ML preprocessing

ફાયદા:

- Common words ને low scores મળે છે (the, and, is)
- Rare પરંતુ important words ને high scores મળે છે
- સરળ અને અસરકારક text analysis માટે

મેમરી ટ્રીક

"TF-IDF - Term Frequency \times Inverse Document Frequency"

પદ્ધતિ 3(અ) OR [3 ગુણ]

ફુરી લોજિક સિસ્ટમ્સ વ્યાખ્યાયિત કરો. તેના મુખ્ય ઘટકોની ચર્ચા કરો.

જવાબ

Fuzzy Logic Systems uncertainty અને partial truth handle કરે છે, completely true અને completely false વર્ષયે values allow કરે છે.

ટેબલ: Fuzzy Logic ઘટકો

ઘટક	કાર્ય	ઉદાહરણ
Fuzzifier	Crisp inputs ને fuzzy sets માં convert કરે છે	Temperature 75 \rightarrow "Warm"(0.7)
Rule Base Inference Engine	If-then fuzzy rules ધરાવે છે Inputs પર fuzzy rules apply કરે છે	IF temp is warm THEN fan is medium Multiple rules combine કરે છે
Defuzzifier	Fuzzy output ને crisp value માં convert કરે છે	"Medium speed" \rightarrow 60% fanspeed

મુખ્ય લાક્ષણિકતાઓ:

- **Membership Functions:** Belonging ની degree (0 થી 1)
- **Linguistic Variables:** Human-like terms (hot, cold, warm)
- **Fuzzy Rules:** Fuzzy conditions સાથે IF-THEN statements

પ્રશ્ન 3(બ) OR [4 ગુણ]

મજબૂતીકરણ શિક્ષણા ઘટકો સમજાવો: નીતિ, પુરસ્કાર સંકેત, મૂલ્ય કાર્ય, મોડેલ

જવાબ

ટેબલ: Reinforcement Learning ઘટકો

ઘટક	વ્યાખ્યા	હેતુ
Policy (નીતિ)	Actions select કરવાની strategy	Agent ના behavior ને define કરે છે
Reward Signal (પુરસ્કાર સંકેત)	Environment તરફથી feedback	Good/bad actions indicate કરે છે
Value Function (મૂલ્ય કાર્ય)	Expected future rewards	Long-term benefit estimate કરે છે
Model (મોડેલ)	Environment નું agent representation	Next state અને reward predict કરે છે

વિગતવાર સમજૂતી:

Policy (π):

- Deterministic: $\pi(s) = a$ (એક state માટે એક action)
- Stochastic: $\pi(a | s) = \text{state } s \text{ માં action } a \text{ ની probability}$

Reward Signal (R):

- Environment તરફથી immediate feedback
- Good actions માટે positive, bad actions માટે negative

Value Function (V):

- State Value: $V(s) = \text{state } s \text{ થી expected return}$
- Action Value: $Q(s,a) = \text{state } s \text{ માં action } a \text{ થી expected return}$

Model:

- Transition Model: $P(s' | s,a) = \text{next state } n \text{ ની probability}$
- Reward Model: $R(s,a,s') = \text{expected reward}$

પ્રશ્ન 3(ક) OR [7 ગુણ]

તફાવત કરો: આવૃત્તિ-આધારિત વિના આગાહી-આધારિત word embedding તકનીકો.

જવાબ

ટેબલ: Frequency-based vs Prediction-based Word Embeddings

પાસું	Frequency-based	Prediction-based
Approach	Count-based statistics	Neural network prediction
ઉદાહરણો	TF-IDF, Co-occurrence Matrix	Word2Vec, GloVe
Computation	Matrix factorization	Gradient descent
Context	Global statistics	Local context windows
Scalability	Matrix size દુરાં limited	Vocabulary સાથે scales

Quality

Basic semantic relationships

Rich semantic relationships

Frequency-based Methods:

- **TF-IDF:** Term frequency \times Inversedocument frequency
- **Co-occurrence Matrix:** Word pair frequency counts
- **LSA:** SVD વાપરીને Latent Semantic Analysis

Prediction-based Methods:

- **Word2Vec:** Skip-gram અને CBOW models
- **GloVe:** Global Vectors for Word Representation
- **FastText:** Subword information inclusion

Code Comparison:

```
\# Frequency{-based (TF{-}IDF)}
from sklearn.feature_extraction.text import TfidfVectorizer
vectorizer = TfidfVectorizer()
tfidf_matrix = vectorizer.fit_transform(documents)

\# Prediction{-based (Word2Vec)}
from gensim.models import Word2Vec
model = Word2Vec(sentences, vector_size=100, window=5)
```

ફાયદા:

Frequency-based:

- સરળ અને interpretable
- Small datasets માટે જરૂરી computation
- Basic similarity tasks માટે સારું

Prediction-based:

- Dense vector representations
- બહેતર semantic relationships
- Large vocabularies માટે scalable

મેમરી ટ્રીક

"FP - Frequency counts, Prediction learns"

પ્રશ્ન 4(અ) [૩ ગુણ]

પ્રતિક્રિયાશીલ મશીનની મુખ્ય લાક્ષણિકતાઓની યાદી બનાવો.

જવાબ

ટેબલ: Reactive Machine મુખ્ય લાક્ષણિકતાઓ

લાક્ષણિકતા	વર્ણન
Stateless	Past interactions ની કોઈ memory નથી
Reactive	જકત current inputs ને respond કરે છે
Deterministic	Same inputs માટે consistent outputs
Specialized	Specific tasks માટે designed
Real-time	Stimuli ને immediate response

ઉદાહરણો:

- **Deep Blue:** Chess-playing computer
- **Google AlphaGo:** Go-playing system (early version)

પ્રશ્ન 4(બ) [4 ગુણ]

વિવિધ પૂર્વ-પ્રોસેસિંગ તકનીકોની સૂચિ બનાવો. તેમાંથી કોઈપણ એકને python code વડે સમજાવો.

જવાબ

ટેબલ: Text Pre-processing તકનીકો

તકનીક	હેતુ	ઉદાહરણ
Tokenization	Text ને words માં split કરવું	"Hello world" → ["Hello", "world"]
Stop Word Removal	Common words remove કરવા	"the", "and", "is" remove કરવા
Stemming	Words ને root form માં reduce કરવા	"running" → "run"
Lemmatization	Dictionary form માં convert કરવા	"better" → "good"

Stemming સમજીતી: Stemming suffixes remove કરીને words ને root form માં reduce કરે છે.

Stemming માટે Python Code:

```
import nltk
from nltk.stem import PorterStemmer

# Stemmer initialize
stemmer = PorterStemmer()

# Example words
words = ["running", "flies", "dogs", "churches", "studying"]

# Stemming apply
stemmed_words = [stemmer.stem(word) for word in words]
print(stemmed_words)
# Output: [run, fli, dog, church, studi]
```

Stemming ના ફાયદા:

- ML models માટે vocabulary size reduce કરે છે
- Related words ને together group કરે છે
- Text analysis efficiency improve કરે છે

પ્રશ્ન 4(ક) [7 ગુણ]

Word2vec તકનીકને વિગતવાર પ્રકાશિત કરો.

જવાબ

Word2Vec એ neural network-based તકનીક છે જે context predict કરીને words ના dense vector representations શીખે છે.

ટેબલ: Word2Vec Architectures

Architecture	Approach	Input	Output
Skip-gram	Center word થી context predict કરે છે	Center word	Context words
CBOW	Context થી center word predict કરે છે	Context words	Center word

Skip-gram Model:

Mermaid Diagram (Code)

```
{Shaded}
{Highlighting} []
graph LR
    A[Input: Center Word] --> B[Hidden Layer]
    B --> C[Output: Context Words]
    C --> D[Softmax Layer]
    D --> E[Probability Distribution]
{Highlighting}
{Shaded}
```

Training Process:

1. **Sliding Window:** Text પર window move કરો
2. **Word Pairs:** (center, context) pairs બનાવો
3. **Neural Network:** Context predict કરવા માટે train કરો
4. **Weight Matrix:** Word vectors extract કરો

મુખ્ય લાક્ષણિકતાઓ:

- **Vector Size:** સામાન્ય રીતે 100-300 dimensions
- **Window Size:** Context range (સામાન્ય રીતે 5-10 words)
- **Negative Sampling:** Efficient training method
- **Hierarchical Softmax:** Softmax ની alternative

Mathematical Concept:

$$\text{Objective} = \max \sum \log P(\text{context} | \text{center})$$

$$P(\text{context} | \text{center}) = \exp(v_{\text{context}} \cdot v_{\text{center}}) / \sum \exp(v_w \cdot v_{\text{center}})$$

Applications:

- **Similarity:** Similar words શોધવા
- **Analogy:** King - Man + Woman = Queen
- **Clustering:** Semantic categories group કરવા
- **Feature Engineering:** ML input features

ફાયદા:

- **Dense Representations:** Rich semantic information
- **Semantic Relationships:** Word meanings capture કરે છે
- **Arithmetic Properties:** Vector operations make sense

મેમરી ટ્રીક

“W2V - Words to Vectors via neural networks”

પ્રશ્ન 4(અ) OR [3 ગુણ]

નેચરલ લેંગ્વેજ પ્રોસેસિંગની કોઈપણ ચાર applications ની યાદી બનાવો. સ્પામ શોધને વિગતવાર સમજાવો.

જવાબ

ટેબલ: NLP Applications

Application	વર્ણન
Spam Detection	Unwanted emails identify કરવા
Sentiment Analysis	Emotional tone determine કરવા
Machine Translation	Languages વાચે translate કરવા
Chatbots	Automated conversation systems

Spam Detection વિગતો:

Process:

1. **Feature Extraction:** Email text ને numerical features માં convert કરો
2. **Classification:** ML algorithms વાપરીને classify કરો
3. **Decision:** Spam અથવા legitimate તરીકે mark કરો

વાપરાયેલા Features:

- **Word Frequency:** Spam keywords count
- **Email Headers:** Sender information
- **URL Analysis:** Suspicious links
- **Text Patterns:** ALL CAPS, excessive punctuation

Machine Learning Approach:

```
\# Simplified spam detection
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.naive_bayes import MultinomialNB

\# Emails features convert
vectorizer = TfidfVectorizer()
X = vectorizer.fit_transform(email_texts)

\# Classifier train
classifier = MultinomialNB()
classifier.fit(X, labels) \# labels: 0=legitimate, 1=spam
```

મેમરી ટ્રીક

``SMTP - Spam, Machine Translation, Sentiment, Phishing detection''

પ્રશ્ન 4(બ) OR [4 ગુણ]

પ્રવચન સંકલન અને વ્યવહારિક વિશ્લેષણ વિશે સમજાવો.

જવાબ

ટેબલ: Discourse Integration vs Pragmatic Analysis

પાસું	Discourse Integration	Pragmatic Analysis
ધ્યાન	Text coherence અને structure	Context અને intention
વ्याप્તि	Multiple sentences/paragraphs	Speaker નો intended meaning
ઘટકો	Anaphora, cataphora, connectives	Implicature, speech acts
લક્ષ્ય	Text flow understand કરવું	Real meaning understand કરવું

Discourse Integration:

- **Anaphora Resolution:** "John went to store. He bought milk." (He = John)
- **Cataphora:** "Before he left, John locked the door."
- **Coherence:** Sentences વાચે logical flow
- **Cohesion:** Grammatical connections

Pragmatic Analysis:

- **Speech Acts:** Commands, requests, promises
- **Implicature:** Literal કરતાં implied meanings
- **Context Dependency:** Same words, different meanings
- **Intention Recognition:** Speaker ખરેખર શું mean કરે છે

ઉદાહરણો:

Discourse Integration:

Text: "Mary owns a car. The vehicle is red."

Resolution: "vehicle" refers to "car"

Pragmatic Analysis:

Statement: "Can you pass the salt?"

Literal: Ability question

Pragmatic: Salt pass request

મેમરી ટ્રીક

"DP - Discourse connects, Pragmatics interprets context"

પ્રશ્ન 4(ક) OR [7 ગુણ]

બેગ ઓફ વર્ડ્સ word embedding technique વિશે વિગતવાર ચર્ચા કરો.

જવાબ

Bag of Words (BoW) એ simple text representation method છે જે documents ને unordered collections of words તરીકે treat કરે છે.

ટેબલ: BoW Process

સ્ટેપ	વર્ણન	ઉદાહરણ
Vocabulary Creation	બધા unique words collect કરો	[``cat'', ``sat'', ``mat'', ``dog'']
Vector Creation	Word occurrences count કરો	[1, 1, 1, 0] for ``cat sat mat''
Document Representation	દરેક document vector બને છે	Multiple documents → Matrix

ઉદાહરણ:

Documents:

1. "The cat sat on the mat"
2. "The dog ran in the park"

Vocabulary: [the, cat, sat, on, mat, dog, ran, in, park]

Document Vectors:

- Doc1: [2, 1, 1, 1, 1, 0, 0, 0, 0]
Doc2: [2, 0, 0, 0, 0, 1, 1, 1]

Python Implementation:

```
from sklearn.feature\_extraction.text import CountVectorizer

documents = [
    "The cat sat on the mat",
    "The dog ran in the park"
]

vectorizer = CountVectorizer()
bow\_matrix = vectorizer.fit\_transform(documents)
vocab = vectorizer.get\_feature\_names\_out()

print("Vocabulary:", vocab)
print("BoW Matrix:", bow\_matrix.toarray())
```

ફાયદા:

- સરળતા: Understand અને implement કરવા માટે સરળ
- Interpretability: Clear word-count relationship
- અસરકારકતા: ઘણા tasks માટે સારં કામ કરે છે

ગેરફાયદા:

- કોઈ Word Order નથી: "cat sat mat" = "mat sat cat"
- Sparse Vectors: Large vocabularies માં ઘણા zeros
- કોઈ Semantics નથી: Word meanings ની કોઈ understanding નથી
- High Dimensionality: Vocabulary size સાથે scales

વિવિધતાઓ:

- Binary BoW: Word present હોય તો 1, absent હોય તો 0
- TF-IDF BoW: Term frequency \times Inversedocument frequency
- N-gram BoW: Word sequences consider કરે છે

Applications:

- Document Classification: Spam detection
- Information Retrieval: Search engines
- Text Clustering: Similar documents group કરવા
- Feature Engineering: ML models માટે input

મેમરી ટ્રીક

``BOW - Bag Of Words counts occurrences''

પ્રશ્ન 5(અ) [3 ગુણ]

ન્યૂરલ નેટવર્કમાં સંક્ષિપ્તકરણ કાર્યોની ભૂમિકા શું છે?

જવાબ

ટેબલ: Activation Function ભૂમિકાઓ

ભૂમિકા	વર્ણન
બિન-રેખીયતા (Non-linearity)	Complex patterns શીખવાને enable કરે છે
આઉટપુટ નિયંત્રણ	Neuron firing threshold determine કરે છે
Gradient Flow	Backpropagation efficiency ને affect કરે છે
રેન્જ મર્યાદા	Output values ને bounds કરે છે

મુખ્ય કાર્યો:

- Decision Making: Neuron activate થવો જોઈએ કે નહીં
- Pattern Recognition: Complex decision boundaries enable કરે છે
- Signal Processing: Weighted inputs ને transform કરે છે

સામાન્ય Activation Functions:

- ReLU: $f(x) = \max(0, x)$ - સરળ અને efficient
- Sigmoid: $f(x) = 1/(1 + e^{-x})$ - Smooth probability output
- Tanh: $f(x) = (e^x - e^{-x})/(e^x + e^{-x})$ - Zero-centered

મેમરી ટ્રીક

“NOGL - Non-linearity, Output control, Gradient flow, Limiting range”

પ્રશ્ન 5(બ) [4 ગુણ]

ન્યૂરલ નેટવર્કના આર્કિટેક્ચરનું વિગતવાર વર્ણન કરો.

જવાબ

ટેબલ: Neural Network Architecture ઘટકો

ઘટક	કાર્ય	ઉદાહરણ
Input Layer	Input data receive કરે છે	Features/pixels
Hidden Layers	Information process કરે છે	Pattern recognition
Output Layer	Final result produce કરે છે	Classification/prediction
Connections	Layers વચ્ચે neurons ને link કરે છે	Weighted edges

Architecture સાયાગ્રહમ:

Mermaid Diagram (Code)

```

{Shaded}
{Highlighting} []
graph LR
    A[Input Layer] --> B[Hidden Layer 1]
    B --> C[Hidden Layer 2]
    C --> D[Output Layer]

    A1[X1] --> B1[H1]
    A2[X2] --> B1
    A1 --> B2[H2]
    A2 --> B2

    B1 --> D1[Y1]
    B2 --> D1
{Highlighting}
{Shaded}

```

Layer કિંતો:

- Input Layer:** Neurons ની સંખ્યા = features ની સંખ્યા
- Hidden Layers:** Variable neurons, complexity માટે multiple layers
- Output Layer:** Neurons ની સંખ્યા = classes/outputs ની સંખ્યા

Information Flow:

- Forward Pass:** Input → Hidden → Output
- Weighted Sum:** $\sum(w_i \times x_i + bias)$
- Activation:** Activation function apply કરો
- Output:** Final prediction/classification

મેમરી ટ્રીક

“IHOC - Input, Hidden, Output, Connections”

પ્રશ્ન 5(ક) [7 ગુણ]

નેચરલ લેંગ્વેજ પ્રોસેસિંગમાં અસ્પષ્ટતાના પ્રકારોની ચાદી બનાવો અને સમજાવો.

જવાબ

Ambiguity NLP માં ત્યારે થાય છે જ્યારે text ના multiple possible interpretations હોય છે, જે automatic understanding ને challenging બનાવે છે.

ટેબલ: NLP Ambiguities ના પ્રકારો

પ્રકાર	વ્યાખ્યા	ઉદાહરણ	ઉક્તિ
Lexical	Word ના multiple meanings	“Bank” (river/financial)	Context analysis
Syntactic	Multiple parse structures	“I saw her duck”	Grammar rules
Semantic	Multiple sentence meanings	“Visiting relatives can be boring”	Semantic analysis
Pragmatic	Context-dependent meaning	“Can you pass salt?”	Intent recognition
Referential	Unclear pronoun reference	“John told Bill he was late”	Anaphora resolution

વિગતવાર સમજૂતીઓ:

Lexical Ambiguity:

- **Homonyms:** Same spelling, different meanings
- ઉદાહરણ: "I went to the bank" (financial institution vs. river bank)
- ઉકેલ: Context વાપરીને word sense disambiguation

Syntactic Ambiguity:

- **Multiple Parse Trees:** Same sentence, different structures
- ઉદાહરણ: "I saw the man with the telescope"
 - મેં telescope વાપરીને man જોયો
 - મેં telescope વાળા man ને જોયો
- ઉકેલ: Statistical parsing, grammar preferences

Semantic Ambiguity:

- **Multiple Interpretations:** Same structure, different meanings
- ઉદાહરણ: "Visiting relatives can be boring"
 - Relatives ને visit કરવા જરૂર boring છે
 - Visit કરવા આવતા relatives boring છે
- ઉકેલ: Semantic role labeling

Pragmatic Ambiguity:

- **Context-dependent:** Situation પર meaning depend કરે છે
- ઉદાહરણ: "It's cold here" (statement vs. window બંધ કરવાની request)
- ઉકેલ: Dialogue systems, context modeling

Referential Ambiguity:

- **Unclear References:** Multiple possible antecedents સાથે pronouns
- ઉદાહરણ: "John told Bill that he was promoted" (કોને promotion મળ્યો?)
- ઉકેલ: Coreference resolution algorithms

Resolution Strategies:

Mermaid Diagram (Code)

```

{Shaded}
{Highlighting} []
graph LR
    A[Ambiguous Text] --> B[Context Analysis]
    A --> C[Statistical Models]
    A --> D[Knowledge Bases]
    B --> E[Disambiguation]
    C --> E
    D --> E
    E --> F[Clear Interpretation]
{Highlighting}
{Shaded}
  
```

NLP Systems પર Impact:

- **Machine Translation:** ખોટા word choices
- **Information Retrieval:** Irrelevant results
- **Question Answering:** Incorrect responses
- **Chatbots:** Misunderstood queries

મેમરી ટ્રીક

“LSSPR - Lexical, Syntactic, Semantic, Pragmatic, Referential”

પ્રશ્ન 5(અ) OR [3 ગુણ]

ન્યૂરલ નેટવર્કમાં ઉપયોગમાં લેવાતા કેટલાક લોકપ્રિય સંક્ષિપ્ત રાણા કાર્યોના નામોની સૂચિ બનાવો.

જવાબ

ટેબલ: લોકપ્રિય Activation Functions

Function	ફોર્મ્યુલા	Range	વપરાશ
ReLU	$f(x) = \max(0, x)$	$[0, \infty)$	Hidden layers
Sigmoid	$f(x) = 1/(1 + e^{-x})$	$(0, 1)$	Binary classification
Tanh	$f(x) = (e^x - e^{-x})/(e^x + e^{-x})$	$(-1, 1)$	Hidden layers
Softmax	$f(x_i) = e^{x_i} / \sum e^{x_j}$	$(0, 1)$	Multi-class output
Leaky ReLU	$f(x) = \max(0.01x, x)$	$(-\infty, \infty)$	Dead neurons solve કરવા

લોકપ્રિય Functions:

- **ReLU**: Hidden layers માં સૌથી વધુ વપરાતું
- **Sigmoid**: Binary problems માટે traditional choice
- **Tanh**: Sigmoid નો zero-centered alternative
- **Softmax**: Multi-class classification માટે standard

મેમરી ટ્રીક

“RSTSL - ReLU, Sigmoid, Tanh, Softmax, Leaky ReLU”

પદ્ધતિ 5(બ્ય) OR [4 ગુણ]

કૃતિમ ન્યૂરલ નેટવર્કમાં શીખવાની પ્રક્રિયા સમજાવો.

જવાબ

Learning Process neural networks માં iterative training દ્વારા error minimize કરવા માટે weights અને biases ને adjust કરવાનો સમાવેશ કરે છે.

ટેબલ: Learning Process Steps

સ્ટેપ	પ્રક્રિયા	વર્ણન
Initialize	Random weights	Small random values સાથે start કરો
Forward Pass	Output calculate કરો	Network દ્વારા input propagate કરો
Calculate Error	Target સાથે compare કરો	Loss function વાપરો
Backward Pass	Gradients calculate કરો	Backpropagation વાપરો
Update Weights	Parameters adjust કરો	Gradient descent apply કરો
Repeat	Process iterate કરો	Convergence સુધી

Learning Algorithm Flow:

Mermaid Diagram (Code)

```

{Shaded}
{Highlighting} []
graph LR
    A[Weights Initialize] --> B[Forward Pass]
    B --> C[Loss Calculate]
    C --> D[Backward Pass]
    D --> E[Weights Update]
    E --> F{Converged?}
    F --> G[Training Complete]
{Highlighting}
{Shaded}

```

Mathematical Foundation:

- **Loss Function:** $L = \frac{1}{n} \sum (target - output)^2$
- **Gradient:** $\nabla L = error \times input$
- **Weight Update:** $w_{new} = w_{old} - \eta \times gradient$
- **Learning Rate:** η update step size control કરે છે

Learning ના પ્રકારો:

- **Supervised:** Labeled examples થી શીખવું
- **Batch Learning:** બધા samples પછી update
- **Online Learning:** એક sample પછી update
- **Mini-batch:** Small batches પછી update

મુખ્ય વિભાગનાઓ:

- **Epoch:** Training data દ્વારા એક complete pass
- **Convergence:** જ્યારે error ઘટવાનું બંધ થાય
- **Overfitting:** Training data memorize કરવું
- **Regularization:** Overfitting prevent કરવાની techniques

મેમરી ટ્રીક

"IFCBU - Initialize, Forward, Calculate, Backward, Update"

પ્રશ્ન 5(ક) OR [7 ગુણ]

નેચરલ લેંગ્વેજ પ્રોસેસિંગના વિવિધ ફાયદા અને ગેરફાયદાની યાદી બનાવો.

જવાબ

ટેબલ: NLP ફાયદા અને ગેરફાયદા

ફાયદા	ગેરફાયદા
સ્વચાલિત ટેક્સ્ટ વિશ્લેષણ	અસ્પષ્ટતા હેન્ડલિંગ
ભાષા અનુવાદ	સંદર્ભ સમજ
માનવ-કમ્પ્યુટર કિયાપ્રતિક્ષિયા	સાંસ્કૃતિક સૂત્રધારતા
માહિતી નિષ્કર્ષણ	કોમ્પ્યુટેશનલ જટિલતા
ભાવના વિશ્લેષણ	ડેટા આવશ્યકતાઓ

વિગતવાર ફાયદા:

બિજ્ઞાનેસ ફાયદા:

- કસ્ટમર સેવા: Automated chatbots અને support
- કાર્ટેન વિશ્લેષણ: Social media monitoring
- ડોક્યુમેન્ટ પ્રોસેસિંગ: Automated summarization
- સર્ચ એન્હાન્સમેન્ટ: બહેતર information retrieval

તકનીકી ફાયદા:

- Scalability:** મોટા text volumes process કરી શકે છે
- સુસંગતતા: Documents પર uniform analysis
- જડપી: Human text processing કરતાં વધુ જડપી
- Integration:** Existing systems સાથે કામ કરે છે

વિગતવાર ગેરફાયદા:

તકનીકી પડકારો:

- અસ્પષ્ટતા: Text ની multiple interpretations
- Context Dependency:** Situation સાથે meaning બદલાય છે
- Sarcasm/Irony: Automatically detect કરવું મુશ્કેલ
- Domain Specificity:** નવા domains માટે models ને retraining જરૂરી

રિસોર્સ આવશ્યકતાઓ:


- મોટા Datasets: લાખો text samples જરૂરી
- કોમ્પ્યુટેશનલ પાવર: Complex models ને GPUs જરૂરી
- એક્સપર્ટ નોલેજ: Linguistics અને ML expertise જરૂરી
- Maintenance:** Models ને નિયમિત updates જરૂરી

ગુણવત્તાની સમર્થ્યાઓ:

- ચોકસાઈ મર્યાદાઓ: 100% accurate નથી
- Bias** સમસ્યાઓ: Training data biases reflect કરે છે
- ભાષા અવરોધો: કેટલીક languages માટે વધુ સારું કામ કરે છે
- Error Propagation:** Pipelines માં mistakes compound થાય છે

Applications vs Challenges:

Mermaid Diagram (Code)



ભવિષ્યના સુધારાઓ:

- બહેતર Context Models: Transformer architectures
- Multilingual Support:** Cross-language understanding
- Few-shot Learning:** ઓછા data requirements
- Explainable AI:** Model decisions ની understanding

મેમરી ટ્રીક

“ALICE vs ACHDR - Automated, Language, Interaction, Content, Extraction vs Ambiguity, Context, Human-nuances, Data, Resources”